

Görüntü İşleme, Segmentasyon ve Hibrit Kenar Çıkarım Yöntemleri ile CNN Yaklaşımları

Mehmet MOLU

2025

1. Giriş

Görüntü işleme, dijital görüntüler üzerinde çeşitli operasyonlar gerçekleştirerek görüntü kalitesini iyileştirmeyi, görüntüden bilgi çıkarmayı veya onu bilgisayar tabanlı diğer sistemler için daha uygun bir hale getirmeyi amaçlayan bir disiplindir. Görüntü analizinin en temel ve kritik aşamalarından biri ise segmentasyondur. Segmentasyon, bir görüntüyü, benzer özelliklere (renk, yoğunluk, doku, kenar vb.) sahip anlamlı bölgelere ayırma işlemidir (Gonzalez & Woods, 2018). Bu işlem, nesne tanıma, tıbbi görüntüleme de tümör tespiti, otonom araçlarda nesne takibi ve video sıkıştırma gibi sayısız uygulamanın temelini oluşturur.

2. Ödev Uygulaması

Ödev konusuna ait, yapılan çalışmanın çıktısı aşağıdadır. 1. Satırda görüntülerin orijinal halleri bulunmaktadır. 2. Satırda Canny + Sobel Hibrit Kenar Çıkarımı algoritması kullanılmıştır. 3. Satırda Wavelet + Canny hibrit kenar çıkarım algoritması kullanılmıştır. 4. CNN yardımcı kenar çıkarımı gerçekleştirilmiştir.



3. Segmentasyon: Tanım ve Çeşitler

3.1. Segmentasyon Nedir?

Segmentasyon, bir görüntüyü pikseller, bölgeler ya da benzerlik gruplarına ayırarak, her bölgeyi anlamlı bir içerikle (örneğin nesne, arka plan) etiketlemeyi amaçlayan işlemdir. Segmentasyon, görüntüdeki nesne sınırlarının net şekilde belirlendiği bir ön işleme adımıdır.

3.2.Segmentasyon Çeşitleri

Segmentasyon yöntemleri, temel aldıkları prensiplere göre çeşitli kategorilere ayrılabilir:

- **Eşikleme (Thresholding) Tabanlı Yöntemler:** En basit segmentasyon yöntemidir. Piksel yoğunluk değerlerini belirli bir eşik değeri (threshold) ile karşılaştırarak çalışır. Genellikle arka plan ve ön planın net bir şekilde ayrılabilmesi için gri seviyeli görüntülerde etkilidir (Otsu, 1979).
- **Kenar (Edge) Tabanlı Yöntemler:** Görüntüdeki yoğunluk değişimlerinin yüksek olduğu bölgeleri (kenarları) tespit ederek nesnelerin sınırlarını belirlemeyi hedefler. Sobel, Prewitt, Laplacian of Gaussian (LoG) ve Canny bu yöntemin klasik örnekleridir.
- **Bölge (Region) Tabanlı Yöntemler:** Benzer özelliklere sahip pikselleri gruplayarak segmentasyonu gerçekleştirir. "Bölge büyütme" (region growing) ve "bölge bölme ve birleştirme" (split and merge) gibi teknikleri içerir.
- **Kümeleme (Clustering) Tabanlı Yöntemler:** Görüntü piksellerini, özellik uzayında benzerliklerine göre kümeler halinde gruplandıran denetimsiz öğrenme yöntemleridir. K-Ortalama (K-Means) algoritması bu alanda sıkça kullanılır.
- **Graf Tabanlı Segmentasyon:** Pikseller düğüm, benzerlik değerleri kenar olarak tanımlanır; graf kesme (cut) yöntemleri ile segmentasyon yapılır.
- **Aktif Kontur / Yılan Modelleri (Snake / Active Contours):** Enerji minimizasyon prensibiyle sınırlar iteratif olarak optimize edilir.
- **Derin Öğrenme Tabanlı Segmentasyon:** U-Net, DeepLab, Mask R-CNN gibi ağlar ile piksel seviyesi sınıflandırma gerçekleştirilir.

Bu yöntemler, uygulama koşullarına (gürültü, aydınlatma değişimi, nesne benzerliği vb.) bağlı olarak farklı başarı gösterir.

4. Hibrit Kenar Çıkarım Algoritmaları

Hibrit kenar çıkarım yöntemleri, farklı tekniklerin avantajlarını birleştirir. Örneğin, Sobel filtresiyle gradyan bilgisi çıkarılıp, Canny ile net sınırlar elde edilebilir; ya da wavelet dönüşümü ile çok ölçekli detay çıkarımı yapılır ve Canny ile filtreleme uygulanır. Amaç, her yöntemin güçlü yönlerini harmanlayarak daha doğru sonuç üretmektir.

4.1. Genel Hibrit Yaklaşım

Hibrit kenar çıkarım yöntemleri, farklı tekniklerin avantajlarını birleştirir. Örneğin, Sobel filtresiyle gradyan bilgisi çıkarılıp, Canny ile net sınırlar elde edilebilir; ya da wavelet dönüşümü ile çok ölçekli detay çıkarımı yapılır ve Canny ile filtreleme uygulanır. Amaç, her yöntemin güçlü yönlerini harmanlayarak daha doğru sonuç üretmektir.

4.2. Canny-Sobel Hibrit Algoritması

Canny algoritması, çok aşamalı, gürbüzlüğü yüksek ve hassas bir kenar dedektörü olarak kabul edilir. Algoritmanın temel adımları şunlardır:

- Gürültüyü bastırmak için Gauss filtresi uygulama,

- Gradyan büyüklüğü ve yönünü hesaplama (genellikle Sobel veya benzeri operatörlerle),
- Kenarları inceltmek için maksimum olmayan bastırma (non-maximum suppression),
- Histerezis eşikleme ile zayıf ve güçlü kenar piksellerini birleştirme (Canny, 1986).

Canny-Sobel hibrit yaklaşımında, genellikle gradyan hesaplama aşamasında standart operatör yerine geliştirilmiş bir Sobel varyasyonu kullanılır veya Sobel operatörünün çıktısı, Canny'nin histerezis eşikleme aşamasına beslenerek daha kesintisiz ve doğru kenar haritaları elde edilmesi hedeflenir. Bu sayede, Sobel'in hesaplama hızı ve basitliği ile Canny'nin gürbüzlüğü ve hassasiyeti birleştirilebilir.

Artılar:

- Sobel yön ve yoğunluk bilgisi sağlar
- Canny'nin güçlü sınır çıkarımı ile birleşince daha net sonuç
- Gürültüye karşı daha dayanıklı hale gelir

Eksiler:

- Eşik değerlerinin ayarlanması dikkat gerektirir
- Yanlış birleşim, hatalı kenarlar oluşturabilir
- Parametre seçimi performansı çok etkiler

4.3.Wavelet + Canny Hibrit Yöntemi

Adımlar:

1. Gri tonlama ve opsiyonel gürültü azaltma
2. Wavelet dönüşümü (örneğin DWT, Haar) ile görüntü low/high frekans bileşenlerine ayrılır
3. LH, HL, HH detay bileşenleri üzerinden kenar bilgisi elde edilir
4. Detay bileşenleri normalize edilip orijinal boyuta ölçeklendirilir
5. Canny algoritması (detay görüntüsü ya da bulanıklaştırılmış görüntü üzerinde) uygulanır
6. bitwise_or gibi yöntemlerle wavelet detay görüntüsü ile Canny sonucu birleştirilir

Artılar:

- Çok ölçekli analiz imkânı
- İnce detayların korunması
- Gürültü bastırılmasında avantaj

Eksiler:

- Yeniden ölçeklendirme sırasında hata oluşabilir
- İşlem süresi klasik yöntemlere göre daha yüksektir
- Parametre (katman seçimi, eşikler) hassas olmalıdır

5. CNN Ve Görüntü İşlemede Kullanımı

Convolutional Neural Networks - CNN'ler, özellikle grid-benzeri yapıdaki verileri (görüntüler) işlemek için tasarlanmış derin öğrenme modelleridir. Geleneksel yapay sinir ağlarına kıyasla, parametre paylaşımı ve yerel bağlantılar sayesinde hesaplama verimliliği sağlar ve özellikle görüntü tanıma, sınıflandırma ve segmentasyon görevlerinde devrim yaratmışlardır (LeCun vd., 1998).

CNN, geleneksel yöntemlerle karşılaştırıldığında şunları sunar:

- Otomatik özellik çıkarımı
- Karmaşık desenleri, dokuları yakalayabilme
- Büyük veri ile yüksek doğruluk
- Katman derinliğiyle soyut temsilleme

5.1. CNN Mimarisi ve Temel Bileşenleri

- **Convolutional Layer:** Ağın temel yapı taşıdır. Görüntü üzerinde öğrenilmiş filtrelerin (kerneller) kaydırılmasıyla yerel özellik haritaları (feature maps) çıkarır. Bu katman, kenar, doku, şekil gibi düşük seviyeli özelliklerden nesne parçaları gibi yüksek seviyeli özelliklere doğru bir hiyerarşik özellik öğrenimi sağlar.
- **Havuzlama Katmanı (Pooling Layer):** Evrişim katmanının çıktısının boyutunu (çözünürlüğünü) küçülterek hesaplama yükünü azaltır ve aşırı uyumun (overfitting) önüne geçer. Maksimum havuzlama (max pooling) ve ortalama havuzlama (average pooling) en yaygın türleridir.
- **Tam Bağlı Katman (Fully Connected Layer):** Geleneksel sinir ağı katmanıdır. Önceki katmanlarda çıkarılan özelliklerin bir araya getirilerek nihai sınıflandırma veya regresyon işleminin yapıldığı katmandır.

5.2. CNN ile Segmentasyon ve Kenar Çıkarımı

CNN'ler, segmentasyon görevlerinde U-Net, SegNet, DeepLab, Mask R-CNN gibi mimarilerle piksel düzeyinde sınıflandırma yapar.

- **Piksel Tabanlı Sınıflandırma:** Her bir piksel, çevresindeki bölgeye (patch) bakılarak bir sınıfa atanır. Bu yöntem doğru ancak hesaplama açısından maliyetlidir.
- **Tam Evrişimli Ağlar (Fully Convolutional Networks - FCN'ler):** Bu mimaride, tam bağlı katmanlar evrişim katmanlarıyla değiştirilir. Bu sayede ağ, herhangi bir boyuttaki girdi görüntüsü için, girişle aynı uzamsal çözünürlükte bir çıktı (segmentasyon haritası) üretebilir (Long, Shelhamer, & Darrell, 2015). FCN'ler, evrişim katmanları sırasında kaybedilen detayları geri kazanmak için "atlayan bağlantılar" (skip connections) kullanır. U-Net (Ronneberger, Fischer, & Brox, 2015) ve SegNet (Badrinarayanan, Kendall, & Cipolla, 2017) gibi mimariler, tıbbi görüntü segmentasyonu ve otonom sürüş gibi alanlarda FCN temelli başarılı modellere örnektir. Bu mimariler, kodlayıcı (encoder) yoluyla özellik çıkarımı ve kod çözücü (decoder) yoluyla segmentasyon haritasının oluşturulması prensibiyle çalışır.

Kenar çıkarımı alanında ise **HED (Holistically-Nested Edge Detection)**, **RCF**, **HCF** gibi yaklaşımlar literatürde öne çıkar.

- **HED (Holistically-Nested Edge Detection):** CNN'in farklı katmanlarından yan çıktılar alınır ve bunlar birleştirilerek kenar haritası çıkarılır.
- **RCF (Richer Convolutional Features):** Daha fazla katmandan zengin öznitelikler çıkarıp kenar haritasını iyileştirir.
- **HCF (Hybrid Convolutional Features):** Farklı düzeylerden çıkarılan öznitelikleri birleşik bir özellik haritasında kaynaştırır ve toplu şekilde kenar tespiti yapar.

6. SONUÇ

Görüntü segmentasyonu, bilgisayarlı görü uygulamalarının temelini oluşturan dinamik bir araştırma alanıdır. Klasik yöntemlerden hibrit algoritmalara ve nihayetinde derin öğrenme tabanlı CNN mimarilerine kadar olan evrim, bu alandaki ilerlemeyi gözler önüne sermektedir. Hibrit kenar çıkarım algoritmaları, mevcut yöntemlerin sınırlamalarını aşmada pratik çözümler sunarken, Evrimsel Sinir Ağları, özellikle büyük veri kümeleriyle beslendiklerinde, üstün doğruluk ve gürbüzlük sağlayarak segmentasyon performansında yeni bir standart belirlemiştir. Gelecekte, bu iki yaklaşımın sinerjisinden doğan, daha az veriye ihtiyaç duyan ve daha açıklanabilir modellerin geliştirilmesi beklenmektedir.

KAYNAKÇA

Badrinarayanan, V., Kendall, A., & Cipolla, R. (2017). SegNet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *39*(12), 2481–2495. <https://doi.org/10.1109/TPAMI.2017.2699184>

Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *PAMI-8*(6), 679–698. <https://doi.org/10.1109/TPAMI.1986.4767851>

Gonzalez, R. C., & Woods, R. E. (2018). *Digital image processing* (4th ed.). Pearson Education.

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, *86*(11), 2278–2324. <https://doi.org/10.1109/5.726791>

Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern*

Recognition (CVPR) (pp. 3431–3440). IEEE Computer Society. <https://doi.org/10.1109/CVPR.2015.7298965>

Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, *9*(1), 62–66. <https://doi.org/10.1109/TSMC.1979.4310076>

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In N. Navab, J. Hornegger, W. M. Wells, & A. F. Frangi (Eds.), *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (pp. 234–241). Springer International Publishing. https://doi.org/10.1007/978-3-319-24574-4_28